

UNIVERSIDAD DE EL SALVADOR
FACULTAD DE INGENIERÍA Y ARQUITECTURA
ESCUELA DE INGENIERÍA DE SISTEMAS INFORMÁTICOS
CURSO DE ESPECIALIZACIÓN “MACHINE LEARNING”
CICLO I 2026



TEMA:

Predicción del Mundial FIFA 2026:
Un Enfoque de Machine Learning con Simulaciones de Monte Carlo

DOCENTE:

Ing. Bladimir Diaz Campos

ALUMNOS:

APELLIDO	NOMBRE	CARNET
Rivas Fuentes	Josías Abner	rf20010
Rosales Molina	Elmer Edenilson	rm20001

San Salvador, El Salvador
2026

El Oráculo del Balón: Predicción Probabilística y Simulación Monte Carlo para la Copa Mundial FIFA 2026

Elmer Edenilson Rosales Molina

rm20001@ues.edu.sv

Josías Abner Rivas Fuentes

rf20010@ues.edu.sv

Resumen—La predicción de resultados en torneos internacionales de fútbol es un desafío complejo debido a la alta varianza y la naturaleza de baja anotación del deporte. Este artículo presenta un enfoque fundamentado en Machine Learning para predecir las probabilidades de resultados a nivel de partido y simular la Copa Mundial de la FIFA 2026 bajo su nuevo formato de 48 equipos.

Mediante el uso de datos históricos de partidos, rankings ELO y valor de mercado, se entrenaron modelos como Regresión Logística y XGBoost. Los resultados muestran que un modelo lineal estandarizado obtiene una mejor calibración probabilística. Usando el mejor modelo, se ejecutaron 100,000 simulaciones de Monte Carlo del torneo completo, estableciendo a España, Francia y Argentina como los principales favoritos.

Index Terms—Machine Learning, Simulación Monte Carlo, Fútbol, Regresión Logística, XGBoost, ELO.

I. INTRODUCCIÓN

La predicción deportiva ha evolucionado desde heurísticas de expertos hasta rigurosos sistemas computacionales y estadísticos. El presente proyecto, “El Oráculo del Balón”, busca abordar el problema de pronosticar el ganador de la Copa Mundial FIFA 2026.

Este mundial presenta un reto estadístico particular: la expansión a 48 equipos y 104 partidos, lo que incrementa la combinatoria y la aparición de selecciones debutantes o con menos rodaje internacional histórico.

El objetivo de este artículo es describir un pipeline de ciencia de datos que estima la probabilidad de que una selección nacional avance y triunfe en el certamen. Para ello, el problema se modela en dos etapas:

1. Entrenamiento de un clasificador probabilístico multi-clase para cada encuentro individual (Victoria Local, Empate, Victoria Visitante).
2. Ejecución de un motor de simulación basado en el método de Monte Carlo que resuelve el fixture de fase de grupos y llaves eliminatorias.

II. METODOLOGÍA

La arquitectura del sistema se diseñó para priorizar la calibración probabilística en lugar de clasificaciones duras, dado que las simulaciones estocásticas requieren que las estimaciones representen fiablemente la incertidumbre del mundo real.

II-A. Adquisición y Preparación de Datos

El conjunto de datos combina múltiples fuentes, destacando resultados históricos internacionales de fútbol (1872–actualidad) y factores de calidad contemporánea:

- **Resultados y Estadísticas:** Datos de marcadores, fechas, equipos y localía.
- **Calidad de Plantilla:** Valor de mercado de los equipos (`market_value_eur`), edad promedio, cantidad de jugadores en el top-5 de ligas de Europa y tamaño de los planteles.
- **Ranking y ELO:** Integración de la clasificación FIFA oficial y la recreación del sistema ELO para capturar de forma inercial la fuerza actual de una selección.

III. ANÁLISIS EXPLORATORIO DE DATOS (EDA)

Con el objetivo de comprender el comportamiento histórico de los partidos internacionales, se realizó un análisis exploratorio sobre las variables más relevantes del conjunto de datos.

III-A. Distribución de Resultados

La Figura 1 muestra la distribución de victorias, empates y derrotas en el dataset histórico. Se observa un desbalance moderado de clases, especialmente en los empates, lo cual justifica el uso de métricas probabilísticas como Log Loss y Brier Score.




Figura 1. Distribución de resultados históricos

III-B. Selecciones con Mayor Rendimiento Histórico

2 presenta las selecciones con mayor número de victorias históricas registradas en el dataset. Brasil, Argentina y Alemania dominan el historial competitivo internacional.

	Team	Historical Wins
0	Brazil	670
1	England	623
2	Germany	597
3	Argentina	590
4	Sweden	541
5	South Korea	536
6	Mexico	511
7	France	476
8	Italy	475
9	Hungary	470
10	Spain	460
11	Netherlands	452
12	Uruguay	428
13	Denmark	401
14	Scotland	400
15	Japan	389
16	Poland	384
17	Russia	383
18	Belgium	380
19	Egypt	378

Figura 2. Top selecciones con más victorias

III-C. Correlación entre Variables

La matriz de correlación permite identificar relaciones entre las variables utilizadas en el entrenamiento. Se observa una fuerte correlación entre el diferencial ELO y la probabilidad de victoria, confirmando su relevancia predictiva.

III-D. Distribución del Rating ELO

La distribución del rating ELO evidencia diferencias significativas entre selecciones de élite y equipos emergentes.




Figura 3. Heatmap de correlación entre variables

Este comportamiento permite al modelo capturar ventajas competitivas históricas.




Figura 4. Distribución del sistema ELO

III-E. Ingeniería de Características

Para evitar el *data leakage* (fuga de datos), se desarrolló un proceso de ingeniería de características puramente retrospectivo.

Las 11 variables más críticas seleccionadas incluyen:

- Diferenciales de calidad:
 - elo_diff
 - rank_diff
 - market_value_diff
 - top5_players_diff
- Estado de forma reciente (últimos 5 partidos):

- `form_win_rate_diff`
- `form_gf_avg_diff`
- `form_ga_avg_diff`

■ Factores contextuales:

- `home_advantage`

Además, se aplicó un peso temporal de decaimiento exponencial:

$$w = e^{-\lambda t}$$

para penalizar la influencia de partidos antiguos en el aprendizaje de los modelos.

III-F. Selección y Entrenamiento de Modelos

Se plantearon dos enfoques con un particionamiento de los datos ordenado temporalmente:

- 80 % entrenamiento (21,386 filas)
- 20 % prueba (5,347 filas)

III-F1. Regresión Logística: Implementada mediante un pipeline que incluye imputación de medianas y escalado estándar (`StandardScaler`). Optimiza el modelo para obtener probabilidades altamente calibradas directamente mediante la estimación de máxima verosimilitud.

III-F2. XGBoost Classifier: Modelo de ensamble de árboles que maneja interacciones no lineales. Emplea la función objetivo `multi:softprob` para obtener una distribución sobre las tres clases.

Parámetros utilizados:

- `max_depth` = 6
- `subsample` = 0.8

IV. EXPERIMENTOS Y RESULTADOS

IV-A. Evaluación a Nivel de Partido

Para un modelo generador de probabilidades, las métricas más importantes son aquellas que miden la distancia entre distribuciones estimadas y reales.

Las métricas empleadas fueron:

- Log Loss
- Brier Score
- Accuracy
- F1-Macro
- MAE

Cuadro I
MÉTRICAS COMPARATIVAS EN CONJUNTO DE TEST

Métrica	Regresión Logística	XGBoost
Log Loss (↓)	0.8733	0.9017
Brier Score (↓)	0.5132	0.5299
Accuracy (↑)	60.38 %	58.40 %
F1-Macro (↑)	0.4447	0.4708
MAE (↓)	0.5629	0.5709

IV-B. Análisis de Resultados

Los resultados indican empíricamente que la Regresión Logística superó al modelo XGBoost en términos de calibración y exactitud general.

Esto ocurre frecuentemente en predicción de fútbol: los modelos complejos como XGBoost tienden a emitir probabilidades sobresalientes en escenarios ruidosos, perdiendo calibración en el proceso, mientras que los modelos lineales regularizados generan fronteras de decisión más conservadoras y balanceadas.

Sin embargo, en clasificación de minorías (empates y sorpresas), XGBoost presenta un desempeño marginalmente superior reflejado en el F1-Macro.

IV-C. Simulación del Mundial 2026

Usando el modelo probabilístico entrenado, se ejecutaron 100,000 simulaciones Monte Carlo del torneo completo bajo el formato de 48 equipos y 104 partidos.

Cuadro II
TOP 10 SELECCIONES CON MAYOR PROBABILIDAD DE CAMPEONAR

Pos.	Selección	Campeonatos	Probabilidad
1	España	13,158	13.15 %
2	Francia	8,818	8.81 %
3	Argentina	8,659	8.65 %
4	Inglaterra	7,640	7.64 %
5	Japón	6,276	6.27 %
6	Croacia	5,657	5.65 %
7	Bélgica	3,736	3.73 %
8	Países Bajos	3,345	3.34 %
9	Brasil	2,893	2.89 %
10	Marruecos	2,844	2.84 %

El resultado proyecta a España como el principal candidato debido a la acumulación actual en rankings, estado de forma y calidad de plantilla.

También destaca el crecimiento de selecciones emergentes como Japón y Marruecos.

V. ANÁLISIS DE LIMITACIONES

A pesar del rigor estadístico, el modelo presenta limitaciones inherentes al deporte:

- **Falta de información sobre debutantes:** Equipos con poco historial competitivo presentan poca evidencia estadística.
- **Lesiones y factor humano:** Lesiones o cambios físicos de jugadores clave no son fácilmente modelables.
- **Incertidumbre táctica:** Estrategias defensivas o cambios técnicos son difíciles de representar sin métricas avanzadas como xG o tracking de presión.

VI. CONCLUSIONES

Este artículo demuestra el valor de aplicar técnicas de Machine Learning y simulaciones estocásticas al ámbito deportivo.

La metodología comprobó que la modelación de diferenciales probabilísticos dentro de una Regresión Logística produce resultados de alta exactitud global y excelente calibración.

La simulación Monte Carlo evidencia que el aumento a 48 equipos incrementa la incertidumbre competitiva y favorece ocasionalmente a selecciones de segundo nivel si obtienen caminos accesibles en el torneo.

Con los datos disponibles al cierre de 2024, el sistema “El Oráculo del Balón” proyecta un mundial dominado por España, Francia y Argentina como principales contendientes.

REFERENCIAS

1. International football results (martj42/international_results, GitHub).
2. Kaggle FIFA World Ranking Dataset (cashn-carry/fifaworldranking).
3. Transfermarkt data via LanusStats.